

DOI:10.16652/j.issn.1004-373x.2024.03.016

引用格式:范钰,范洪博.基于图神经网络的推荐系统模型[J].现代电子技术,2024,47(3):85-90.

基于图神经网络的推荐系统模型

范钰, 范洪博

(昆明理工大学 信息工程与自动化学院, 云南 昆明 650500)

摘要:为了解决各种在线应用中信息爆炸的相关问题,增强用户体验,学者们开发了基于用户偏好的推荐系统,尽管已经为更加个性化的推荐做了大量的努力,但是推荐系统仍然面临着一些挑战,如数据稀疏性和冷启动问题。针对上述问题,提出一种基于知识图神经网络的推荐模型,将每个意图建模为KG关系的注意组合,强调不同意图的独立性,以获得更好的模型能力和可解释性。实验结果表明,该模型在一定程度上提高了推荐的精准度和推荐效果。

关键词:推荐系统;知识图谱;图神经网络;嵌入式传播;注意力机制;意图独立

中图分类号: TN711-34; TN391.3

文献标识码: A

文章编号: 1004-373X(2024)03-0085-06

Recommender system model based on graph neural network

FAN Yu, FAN Hongbo

(Faculty of Information Engineering and Automation, Kunming University of Science and Technology, Kunming 650500, China)

Abstract: In order to solve the related problems of information explosion in various online applications and enhance user experience, scholars have developed recommender systems based on user preferences. Although a lot of efforts have been made for more personalized recommendations, recommender systems still face some challenges, such as data sparsity and cold-start problems. In view of the above, a recommendation model based on knowledge graph neural network (GNN) is proposed, which models each intention as an attention combination of KG relations, and makes different intentions independent to obtain better model ability and interpretability. The experimental results show that the proposed model improves its recommendation accuracy and recommendation effect to a certain extent.

Keywords: recommendation system; knowledge graph; GNN; embedded propagation; attention mechanism; intentional independence

0 引言

随着数字化信息技术和互联网技术的不断演进和发展,用户获得和浏览信息的方式产生了翻天覆地的变化,信息量呈爆炸式增长,带来了信息过载问题,这种问题使人们对有效信息的筛选变得十分困难。为解决以上难题,推荐技术的应用逐步进入了人们的生活,通过利用用户与项目的历史交互数据,对用户未观测到项目的感兴趣度进行预测,并对预测结果进行排序,推荐给相关用户。

基于商品的协调过滤算法首次由文献[1]提出,该算法原理简单、效果显著,是目前在推荐系统领域应用最广泛的技术。传统的协同过滤算法主要分析用户和项目的交互数据,根据用户或项目之间的相似度来判断用

户偏好并进行推荐,尽管协调过滤算法取得了巨大的成功,但该算法对于解决数据冷启动和数据稀疏性问题仍然面临着巨大的挑战。

随着知识图谱、分子结构等图形数据的大量涌现,业内刮起了一股基于图神经网络(GNN)的研究热潮。GNN结合了卷积神经网络(CNN)和图表示学习(GRL)两大技术^[2-3],CNN能从欧几里德数据中高效提取局部特征,但是当CNN的处理对象为知识图谱这种非欧几里德数据时,由于传统的离散卷积在非欧几里德数据上无法保持平移不变性,存在一定的局限性;GRL是用于实现将图的节点、边或者子图生成低维向量的新兴技术。基于GNN的推荐方法结合协同过滤以及传播思想,采用嵌入传播迭代地聚合邻域嵌入,通过堆叠传播层,使得每个节点都能访问到高阶邻居信息,这弥补了传统推荐方法只能访问一阶信息的不足,有助于解决协调过滤推荐系统的冷启动问题。因此图神经网络的发

展带给许多学者启发。文献[4]提出了 GraphSAGE, GraphSAGE 执行邻域采样,在每个训练过程中只更新相关的子图,显著降低了 GNN 的计算复杂度,提高了模型的可扩展性。文献[5]成功将 GraphSAGE 落地到大规模网络的推荐系统中,并能高效处理数十亿条内容嵌入。除此之外,一些灵活的开源工具也得到发展,如 Pyg^[6]、DGL^[7]以及 AliGraph^[8]等。在后续工作中,文献[9]提出 NGCF,优化了高阶信息中子图结构的使用,取得了不错的推荐性能。文献[10]提出了 LightGCN,去掉了 NGCF 中特征变换和非线性激活部分,经过消融实验对比,该模型在大大降低模型训练量的同时也相对提升了性能。文献[11]在 LightGCN 基础上提出了 UltraGCN,该模型通过对损失进行约束从而直接逼近无线层图卷积的极限,并尝试不同的边缘权重分配,训练效率相比 LightGCN 提高了 10 倍以上。文献[12]提出了 KGCN,引入知识图从实体的邻居中抽取样本作为其接受域,然后将邻域信息与偏差相结合计算实体的表示。接受域可以扩展到多次跳离,以模拟高阶接近性信息,并捕获用户潜在的长距离兴趣。文献[13]提出了 KGIN,该模型引入辅助项目知识来探索用户项目交互的背后意图,在推荐准确性上有了较大提升,一定程度上提升了模型的可解释性。总的来说,基于知识图的图卷积神经网络推荐越来越成为推荐技术的主流研究方向。

1 相关介绍

为了有效提高推荐系统的性能,本文提出了一种基于注意力机制的最终节点表示方法的 KGIN-W 模型作为 KGIN 的改进模型。KGIN 模型是一种新的基于知识图谱的意图网络推荐模型,在设计上尝试利用知识图谱中多样的关系进行意图建模,将每一个意图建模为知识图谱的注意力组合,为了获得更好的解释性和建模能力,模型设计了独立性建模方案来确保不同意图之间的独立性,相较于之前 GNN 单纯聚合邻居节点的方式,提出关系路径聚合的方案,递归整合高阶连通关系形成关系序列。经过用户意图建模和关系路径聚合,有力地帮助模型提取用户意图信息,并编码成用户和项目的集成表示。

下面将从用户意图建模、关系路径聚合以及模型预测三个方面来介绍该模型。

1.1 用户意图建模

现实生活中用户选择某一个项目是基于多种因素综合考量的结果,这种综合的考量因素可以表征为特定的意图,也可以理解为用户选择该项目的原因,在一定程度上能够反映同一个环境下所有用户行为的共性。

以图书推荐为例,意图可能是对于图书不同属性的考虑,如作者和图书类型的组合,亦或者评分和图书类型的组合。针对不同的用户行为模式,可以抽象出不同的意图,以此更细粒度的增强协同过滤的效果,即拥有相似意图的用户对于项目有着相似的偏好。下面将介绍具体的建模过程。

1.1.1 意图嵌入

KGIN 为每一个意图分配一个知识图谱的关系分布,假定 P 是所有用户共享的意图集合,据此将每一个用户和项目交互 (u, i) 分解成 $\{(u, p, i) | p \in P\}$, 根据形成的用户-意图-项目三元组形成一个新的异构图,称之为意图图,并使用注意力策略来创建意图嵌入。

$$e_p = \sum_{r \in R} \alpha(r, p) e_r \quad (1)$$

式中: $\alpha(r, p)$ 是注意力得分; e_p 为意图嵌入; e_r 为关系嵌入。每一个关系 r 的嵌入都会分配一个注意力得分,以此来帮助量化每一个意图中特定关系 r 的重要性。注意力得分实现如式(2)所示:

$$\alpha(r, p) = \frac{\exp(w_p)}{\sum_{r' \in R} \exp(w_{r'})} \quad (2)$$

式中 w_p 是特定关系 r 和特定意图之间的可训练权重。

1.1.2 意图独立性建模

意图建模的目的是通过具有特定含义的意图来描述用户的个性化偏好,不同的意图应该尽可能包含不同的用户偏好信息,如果一个意图能够被其他意图表示或者推断出来,那么这个意图很有可能就是一个冗余的,信息量少的意图应当被摒弃。为了获得更好的模型性能和可解释性,意图应尽量彼此独立, KGIN 模型考虑从统计学角度来实现意图独立,比如余弦相似度以及距离系数。

1.2 关系路径聚合

在 KGIN 模型前,基于 GNN 的推荐模型都通过优异的性能证明了邻居节点聚集机制的优势,但是单纯的节点聚集会限制知识图谱信息带来的收益。这是因为聚合器在聚合邻域信息时没有区分信息的来源,无法判断信息路径,另外,通过注意力机制对知识图谱关系建模来控制邻域传播的方式,会限制知识图谱中关系对于节点的贡献,无法显式地捕捉到关系路径。KGIN 由此提出了关系路径聚合的方式,以下为关系路径聚合的详细说明。

1.2.1 意图图上的聚合

对于用户-项目交互二部图拓展而成的意图图,从中间提取协同过滤信息作为用户偏好特征。在意图图

中,根据具有相似意图的用户对项目具有相似偏好这一假设进行细粒度的意图捕获,对于用户 u ,可以使用 $A_u = \{(p,i) | (u,p,i) \in \mathbf{C}\}$ 来表示围绕 u 的一阶连通信息。如式(3)所示,通过一阶连通信息集成用户历史交互项目的意图信息。

$$e_u^{(1)} = \text{Agg}_{\text{IG}}\left(\left(e_u^{(0)}, e_p, e_i^{(0)}\right) | (p,i) \in A_u\right) \quad (3)$$

用户的一阶嵌入是由零阶嵌入聚合而成,其中 $\text{Agg}()$ 是 GCN 聚合函数,公式如下:

$$e_u^{(0)} = \frac{1}{|A_u|} \sum_{(p,i) \in A_u} \beta(u,p) e_p \odot e_i^{(0)} \quad (4)$$

式中: $e_i^{(0)}$ 是项目 i 的 ID 嵌入;“ \odot ”是元素点积(相同位置的元素逐个元素相乘),相较于其他模型采用衰减因子或者正则化思想,元素点积更有利于突出意图关系在聚集中的作用; $\beta(u,p)$ 是注意力权重,引入 $\beta(u,p)$ 来帮助评判不同的意图 p 对于用户的重要性。

$$\beta(u,p) = \frac{\exp(e_p^T e_u)}{\sum_{p' \in P} \exp(e_{p'}^T e_u)} \quad (5)$$

1.2.2 知识图谱上的聚合

一个实体可以涉及多个知识图谱三元组,因此可以将其他连接的实体作为其属性,这些属性体现了项目之间的内容相似度。利用 $A_i = \{(r,v) | (i,r,v) \in G\}$ 表示项目 i 的属性和一阶连通性,其中 r 代表关系, i 代表项目, v 代表知识图谱中的实体, G 为知识图谱。由知识图谱中实体连接带来的关系感知信息可以生成项目 i 的表示:

$$e_i^{(1)} = \text{Agg}_{\text{KG}}\left(\left(e_i^{(0)}, e_r, e_v^{(0)}\right) | (r,v) \in A_i\right) \quad (6)$$

式中: $e_i^{(1)}$ 是一阶连通性聚合信息的嵌入表示; $\text{Agg}()$ 是从每个连接 (i,r,v) 中提取聚合信息的 GCN 聚焦函数。每一个知识图谱的实体在不同的关系上下文中应该具有不同的语义,比如某人可能是某项目的负责人,也有可能是另一个项目的成员。以往的模型只通过注意力机制模拟衰变因素中的知识图谱关系。

$$e_i^{(1)} = \frac{1}{|A_i|} \sum_{(r,v) \in A_i} e_r \odot e_v^{(0)} \quad (7)$$

式中 $e_v^{(0)}$ 是知识图谱实体的 ID 嵌入。对于每一个三元组 (i,r,v) ,在 KGIN 中通过关系 r 建模为旋转因子,从而使关系消息能够在三元组具有相同实体的情形下帮助揭示三元组携带的不同信息。对于高阶的实体 ID 嵌入 $e_v^{(l)}$ 也可以通过类似的方法获得。

1.2.3 关系路径的捕获

在对用户和项目进行一阶连通性建模后,模型需要

堆叠更多聚合层,收集来自高阶邻居有影响力的信息,对于用户和项目的高阶信息建模如下:

$$e_u^{(l)} = \text{Agg}_{\text{IG}}\left(\left(e_u^{(l-1)}, e_p, e_i^{(l-1)}\right) | (p,i) \in A_u\right) \quad (8)$$

$$e_i^{(l)} = \text{Agg}_{\text{KG}}\left(\left(e_i^{(l-1)}, e_r, e_v^{(l-1)}\right) | (r,v) \in A_i\right) \quad (9)$$

式中: $e_u^{(l-1)}$ 、 $e_i^{(l-1)}$ 、 $e_v^{(l-1)}$ 分别表示用户 u 、项目 i 和实体 v 的嵌入表示,包含了基于自身 $(l-1)$ 跳的邻居关系信号,这些表示聚集了多跳路径的整体语义,能够突出关系依赖性,例如 $s = i \xrightarrow{r_1} s_1 \xrightarrow{r_2} s_2 \cdots s_{l-1} \xrightarrow{r_l} s_l$, 这是一个以项目 i 为起始节点的 l 跳路径,该路径中包含了一系列相连的三元组。其中关系路径可以表示为关系序列 (r_1, r_2, \dots, r_l) , 因此能够将 $e_i^{(l)}$ 写成如下形式:

$$e_i^{(l)} = \sum_{s \in N_i^l} \frac{e_{r_1}}{|N_{s_1}|} \odot \frac{e_{r_2}}{|N_{s_2}|} \odot \cdots \odot \frac{e_{r_l}}{|N_{s_l}|} \odot e_{s_l}^{(0)} \quad (10)$$

式中 N_i^l 是所有以项目 i 为根节点的 l 跳路径的集合。由公式(10)可以看出,该表示方式能够反映关系之间的相互作用,从而保留路径的整体语义。

1.3 模型预测

模型通过对不同层的用户项目信息分别聚合,经过 L 层的运算之后,可以获得用户 u 和项目 i 在不同层上的表示,最后对各层进行组合得到最终的表示:

$$e_u^* = \sum_{0 \leq l \leq L} e_u^{(l)} \quad (11)$$

$$e_i^* = \sum_{0 \leq l \leq L} e_i^{(l)} \quad (12)$$

得到最终的用户和项目表示后,以二者的内乘即余弦相似度来预测用户采用该项目的可能性:

$$\text{score}_{ui} = e_u^{*T} e_i^* \quad (13)$$

2 本文提出的方法

在图嵌入部分对意图独立性建模进行调研,选择了最佳的互信息方案;引入注意力机制对各聚合层嵌入加权组合生成用户和项目最终表示。模型结构如图1所示。其中:打框部分为模型改进部分; e_u 、 e_i 、 e_p 、 e_v 、 e_r 分别为用户嵌入、项目嵌入、意图嵌入、知识图谱实体嵌入与知识图谱关系嵌入; $e_{u_{\text{fin}}}$ 和 $e_{i_{\text{fin}}}$ 分别为用户和项目最终表示。

在 KGIN-W 模型中,用户和项目嵌入能够训练的是第0层的嵌入,后续不同层的嵌入则通过不断的 GCN 聚集与更新操作生成,为进行最终的预测任务,需要对不同层的嵌入进行整合生成最终用户和项目表示,具体如图2所示。

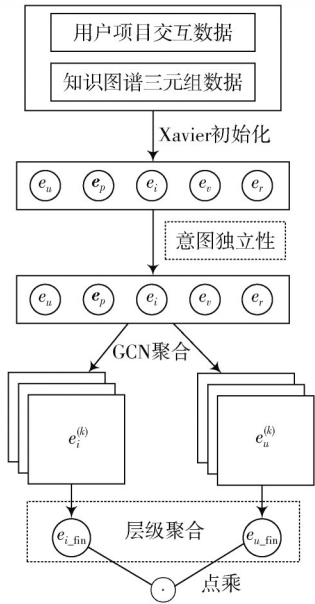


图1 KGIN-W模型部分架构

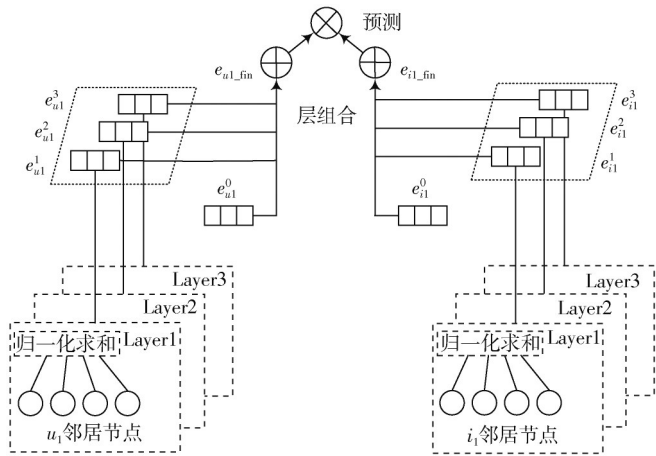


图2 层嵌入组合图

在模型中,不同层的嵌入具有不同的语义,以用户嵌入为例,第一层嵌入包含用户和项目的交互信息,第二层则捕获有相同交互项目的用户信息,更高层则能捕捉更高阶的邻域信息。当前主流的组合方法是使用GCN聚集最后一层的节点向量作为最终表示,以用户最终表示为例,即 $e_u^* = e_u^L$ 。然而简单地使用最后一层作为最终表示,一方面无法区分高低阶信息的重要性,另一方面,随着层数增加,嵌入会出现过度平滑的情况。

2.1 数据集介绍

本文依托科研管理平台构建科研推荐数据集。科研推荐数据集主要由用户项目交互数据以及知识图谱数据两部分组成。

1) 用户项目交互数据的生成。首先,收集科研管理平台数据库科研人员申请、参与以及查看项目所产生的数据记录,然后过滤,去除掉稀疏的交互信息,最后将

用户以及项目的唯一性ID映射到科研推荐数据集。

2) 知识图谱数据的生成。首先,从科研领域知识图谱数据库中获得三元组信息,其中包含实体信息以及连接实体的关系信息。在获取三元组信息后,对关系信息以及实体信息进行ID编码输出,其中需要将交互信息中项目与图谱实体一一关联。

获取的数据都以结构化形式呈现。数据量概况如表1所示。

表1 推荐数据集信息

类型	数目
用户数	77 719
项目数量	104 684
交互数	471 772
实体数	623 937
关系种类	17
三元组数	2 015 809

对于科研推荐数据集,本文将知识图谱中具有丰富信息的三元组数据与用户交互数据作为样本数据,其中知识图谱三元组信息作为辅助信息,交互数据作为用户个性化信息的载体。在本次实验中,通过相应数据处理模块对用户项目交互数据进行随机切割,其中80%用作训练集用以帮助模型训练,剩余的20%作为测试集用以评估模型性能。

2.2 实验设置

通过模型对比实验验证本文改进方案的有效性。以下所有的实验内容都是基于科研推荐数据集,均在训练集上进行训练,在测试集上进行评估。

KGCN模型:KGCN是知识图谱和用户项目交互的GNN推荐模型,该模型通过有选择、有偏差地聚合邻居信息,然而在该模型中仅仅聚合简单的几层邻居信息,没有深入分析用户的偏好。

KGAT模型:KGAT是基于知识图谱和用户项目交互的GNN推荐模型,该模型基于节点邻居的嵌入来迭代更新节点嵌入,能捕获高阶连接,另外加入了注意力机制来学习不同邻居节点的权重。然而在该模型中没有细粒度地分析用户的偏好,并且缺乏对于关系语义的保留。

基础模型KGIN模型:该模型相较于KGAT模型而言,在对用户和项目进行表示的过程中,加入了关系语义嵌入,并且利用图谱中的关系对意图进行建模,细粒度地挖掘了用户的偏好,取得了更优异性能的同时获得了更好的可解释性。

KGIN-W 模型:该模型相较于 KGIN 模型,在各层的用户和项目表示融合形成最终用户项目表示时,加入了权重机制区分各层的重要性。

基于模型质量和训练成本的考量,为保证测试的效果,对所有测试模型参数设置如下:采用 Xavier 初始化方法初始化可训练参数,优化器固定为 Adam 优化器^[14],批次处理大小固定为 1 024,学习率设置为 0.000 1,嵌入维度设置为固定的 64,控制独立性损失权重的相似度正则化参数设置为 0.000 1。

模型对比实验中,除 KGCN 模型和 KGAT 模型外,KGIN、KGIN-W 模型的独立性建模方案都设置为互信息建模方案,GCN 聚集层数为 3 层,用户意图粒度为 4。对于 KGAT 模型,通过矩阵分解预训练获得初始嵌入,其余两种对比模型无需预训练。

2.3 评估指标

召回率(Recall)与归一化折损累计增益(NDCG)是反映推荐列表质量的单值指标。

召回率用于 Top-N 推荐系统,主要的评价方式是通过计算预测前 N 个项目与用户实际交互项目的交集大小再除以用户实际交互项目的集合大小,该指标能反映推荐中有多少正样本进入了推荐列表,然而召回率是与顺序无关的推荐评价指标,无法反映列表排序质量,因而需要结合下文的 NDCG 指标进行综合评价。

$$\text{recall}@N = \frac{1}{|\text{User}|} \sum_{u \in \text{User}} \frac{|\{\text{predictTop}N\} \cap \{\text{histroy}\}|}{|\{\text{histroy}\}|} \quad (14)$$

NDCG 是排序结果的常用评价指标,用于评判排序的准确性。以本文推荐模型为例,针对某个用户返回推荐项目列表,假定列表长度为 N,此时可使用 NDCG@N 来评价,以此判断生成的排序列表与用户的真实交互列表之间的差距。

通过结合 Recall 和 NDCG 两个评估指标,可以更加全面地衡量模型推荐性能,保证推荐的质量。一般而言,用户面对推荐列表时只会对推荐排名靠前的项目有兴趣,因而实验中不会获取所有的项目评分,此处将推荐的排名列表长度设置为:(20,40,60,80,100),以此计算相应的 Recall 和 NDCG,并进行评估。

2.4 实验结果

实验结果如表 2 和表 3 所示。由表 2 和表 3 的数据绘制图 3 以及图 4,并进行分析。

首先 KGAT、KGIN 以及 KGIN-W 的召回率和 NDCG 相较 KGCN 有着明显的提升,并且当推荐列表的长度不断增加时依然具有相对优异的性能。证明融入用户意图以及关系路径聚合方案模型能更加精确地捕获用户的偏好,提高嵌入的质量,提升推荐性能。

表 2 各个模型召回率统计

模型	recall_20	recall_40	recall_60	recall_80	recall_100
KGCN	0.304 8	0.356 8	0.393 6	0.418 1	0.440 6
KGAT	0.344 5	0.383 3	0.415 5	0.442 9	0.461 8
KGIN	0.353 5	0.392 1	0.417 2	0.432 8	0.451 7
KGIN-W	0.374 3	0.411 5	0.436 9	0.456 3	0.472 4

表 3 各个模型 NDCG 统计

模型	ndcg_20	ndcg_40	ndcg_60	ndcg_80	ndcg_100
KGCN	0.194 1	0.205 3	0.211 4	0.216 8	0.220 1
KGAT	0.208 1	0.221 4	0.229 2	0.234 6	0.238 7
KGIN	0.221 7	0.230 5	0.234 9	0.238 5	0.240 7
KGIN-W	0.232 4	0.241 1	0.245 6	0.249 0	0.251 7

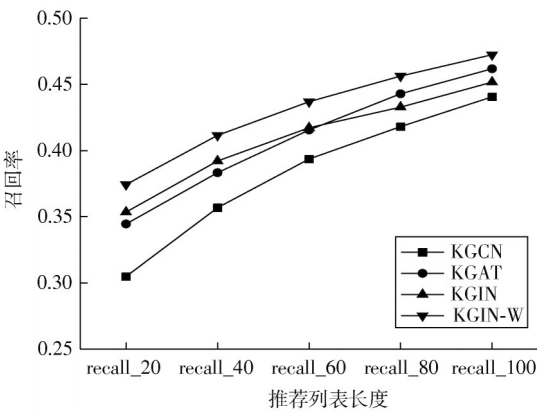


图 3 模型推荐结果召回率评估指标




图 4 模型推荐结果 NDCG 评估指标

另外在推荐长度为 20 时,KGIN-W 召回率及 NDCG 优于 KGIN,KGIN-W 相对 KGIN 召回率提升 5.88%,代表列表排序质量的 NDCG 提升了 4.83%。通过分析训练完成的模型参数,可训练层权重参数在低层表示权重更高,这表明对模型而言,低阶信息相较高阶信息更能反映用户偏好。从数据集分布上考量,不同于用户选购商

品的离散化表现,科研人员更关注与其关系更密切的交互项目,因而更加注重低阶信息的权重分布,更能反映科研人员的真实意图,然而对低阶信息的关注意味着在推荐远距离目标时,推荐性能不可避免的下降。考虑到系统中用户对于推荐列表一般比较关注排名靠前的部分,对于靠后的推荐很少浏览,综合考量系统需求和模型性能后,选择以加权层嵌入组合形成最终表示的方案进行训练与实验。

最后,KGIN-W的召回率和NDCG评估相较KGIN以及KGAT有着明显的提升,KGIN-W具有最佳性能。KGIN-W的召回率提升主要来源于权重机制的加入让模型在Top-20推荐时更加准确,推荐列表质量更高。

3 结 语

本文提出了一个KGIN的改进模型KGIN-W,分析说明了模型的架构、改进点,并通过实验评估比较了模型性能。本文在对KGIN模型进行详细分析后,为深入探索用户兴趣并更加精准地推荐项目,首先对KGIN模型中独立性建模方案做了细致的调研,经过理论分析和实验论证,选择了性能最佳的互信息方案;然后对KGIN层嵌入组合方式进行改进,引入了注意力机制,以此更好地区分不同层信息对于最终表示的影响;最后,本文通过模型对比实验证明了KGIN-W的训练效率以及推荐性能的优越性。但实验也存在不足之处,在对KGIN中的损失函数调研中发现,原有的BPR损失函数在训练速度和区分正负样本的性能上稍显不理想,应考虑设计一个个性化兴趣边界损失函数,以此帮助模型更快更好地区分正负样本。所以接下来的工作重点将放在这一方向。

注:本文通讯作者为范洪博。

参 考 文 献

- [1] RESNICK P, IACOVOU N, SUCHAK M, et al. GroupLens: An open architecture for collaborative filtering of Netnews [C]// Proceedings of the Conference on Computer Supported Cooperative Work. New York: ACM, 1994: 175-186.
- [2] WU Z H, PAN S R, CHEN F W, et al. A comprehensive survey on graph neural networks [J]. IEEE transactions on neural networks and learning systems, 2021, 32(1): 4-24.
- [3] XIA L, HUANG C, XU Y, et al. Multi-behavior enhanced recommendation with cross-interaction collaborative relation modeling [C]// 2021 IEEE 37th International Conference on Data Engineering (ICDE). New York: IEEE, 2021: 1931-1936.
- [4] HAMILTON W L, YING R, LESKOVEC J. Inductive representation learning on large graphs [EB/OL]. [2018-08-13]. <http://arxiv.org/abs/1706.02216>.
- [5] YING R, HE R, CHEN K, et al. Graph convolutional neural networks for web-scale recommender systems [C]// The 24th ACM International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2018: 1-10.
- [6] FEY M, LENSSEN J E. Fast graph representation learning with PyTorch geometric [EB/OL]. [2019-03-31]. <http://arxiv.org/abs/1903.02428>.
- [7] WANG M, YU L, ZHENG D, et al. Deep graph library: Towards efficient and scalable deep learning on graphs [EB/OL]. [2021-11-25]. <http://arxiv.org/abs/1909.01315>.
- [8] ZHU R, ZHAO K, YANG H, et al. AliGraph: a comprehensive graph neural network platform [J]. Proceedings of the VLDB endowment, 2019, 12(12): 2094-2105.
- [9] WANG X, HE X, WANG M, et al. Neural graph collaborative filtering [C]// Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2019: 165-174.
- [10] HE X, DENG K, WANG X, et al. LightGCN: simplifying and powering graph convolution network for recommendation [C]// Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2020: 639-648.
- [11] MAO K, ZHU J, XIAO X, et al. UltraGCN: Ultra simplification of graph convolutional networks for recommendation [C]// The 30th ACM International Conference on Information and Knowledge Management, Virtual Event. New York: ACM, 2021: 1253-1262.
- [12] WANG H, ZHAO M, XIE X, et al. Knowledge graph convolutional networks for recommender systems [C]// The World Wide Web Conference. New York: ACM, 2019: 3307-3313.
- [13] WANG X, HUANG T, WANG D, et al. Learning intents behind interactions with knowledge graph for recommendation [C]// The Web Conference 2021 on Virtual Event. New York: ACM, 2021: 878-887.
- [14] KINGMA D, BA J. Adam: A method for stochastic optimization [EB/OL]. [2019-07-25]. <http://arxiv.org/abs/1412.6980>.

作者简介:范钰(1998—),男,四川中江人,硕士研究生,主要研究方向为深度学习、推荐系统。

范洪博(1982—),男,黑龙江绥化人,博士,讲师,主要研究方向为深度学习、人工智能、区块链技术。